

Talep Tahmini ve Stok Optimizasyonu ile Fazla Stok ve Stoksuz Kalma Problemlerini Çözme

Nuh HATİPOĞLU

11 Nisan 2025

- 1 Giriş
- 2 Sentetik Veri Üretimi ve Yapısı
- 3 Tahmin (Forecasting) Modelleri
- 4 Train / Test Veri Seti Hazırlanması
- 5 Model Eğitim ve Test Sonuçları
- 6 Başarım Metrikleri
- 7 İşletme Parametreleri ile Hesaplamalar
- 8 Tahmin ve Optimizasyon
- 9 Agent Analizleri

- Hızlı moda sektöründe talep tahmini ve stok optimizasyonu önemlidir.
- Veri bilimi ve yapay zeka kullanarak karar destek sistemleri geliştirilmiştir.
- Proje, geçmiş satış verileri, ürün varyantları, kampanyalar ve kanal bilgilerini kullanmaktadır.
- Amaç, talep tahminleri ve stok optimizasyon kararları vermektir.
- Proje üç temel fazdan oluşmaktadır:
 - Sentetik veri üretimi
 - Çoklu makine öğrenimi modeliyle talep tahmini
 - Stok kararlarını veren bir akıllı ajan sistemi


- Gerçek verilere oldukça yakın şekilde 2019–2025 yılları arasını kapsayan sentetik veriler oluşturulmuştur. Bu veri seti aşağıdaki alt kümeleri içerir:
 - products.csv: Ürün, kategori, beden ve renk varyant bilgileri
 - sales_data.csv: Günlük satış adetleri (ürün, varyant, mağaza, kanal bazlı)
 - campaigns.csv: Kampanya tarihleri ve açıklamaları

Ürün Varyantları Tablosu

Product ID	Kategori	Alt Kategori	Renk	Beden
1	Çocuk Giyim	Body	Kırmızı	M
1	Çocuk Giyim	Body	Kırmızı	XS
1	Çocuk Giyim	Body	Kırmızı	S
1	Çocuk Giyim	Body	Beyaz	M
1	Çocuk Giyim	Body	Beyaz	XS
1	Çocuk Giyim	Body	Beyaz	S
1	Çocuk Giyim	Body	Yeşil	M
1	Çocuk Giyim	Body	Yeşil	XS
1	Çocuk Giyim	Body	Yeşil	S
2	Kadın Giyim	Bluz	Kırmızı	M


Tablo: Ürünlerin kategori, alt kategori, renk ve beden varyantları

- Tüm varyant kombinasyonları (örneğin Ürün A - Renk Mavi - Beden L) günlük olarak satış verisine sahiptir.
- Fiziksel ve Online olmak üzere iki ana kanal, 50 mağaza üzerinden modellenmiştir.




Şekil: Kategori bazında ürün sayılarının dağılımı.

- Ürün portföyünün büyük kısmı Erkek Giyim kategorisinde yoğunlaşmıştır. Kadın ve Çocuk Giyim kategorileri daha az ürün içerir.
- Bu dağılım, tahmin modellerinin veri dengesizliği nedeniyle erkek ürünlerine daha duyarlı hale gelmesini sağlayabilir.



Şekil: Aylık bazım toplam satış miktarları

- Haziran–Ağustos aylarında satışlar zirve yaparken, Şubat ayında en düşük seviyeye gerilemektedir.
- Bu dönemsel etki, tahmin modellerine mevsimsellik bileşenlerinin dahil edilmesini zorunlu kılar.



Şekil: İndirim oranı ve satış arasındaki ilişki grafiği

- Kampanya dönemlerinde uç değerlerin artması dikkat çekicidir.
- Ancak ortanca değerlerde belirgin fark yoktur.
- Bu durum, kampanyaların satışları bazı ürünlerde artırdığını ama genel dağılımı çok değiştirmedeğini gösterir.

Tahmin (Forecasting) Modelleri: Tahmin (Forecasting) Modelleri

Ürünlerin varyant bazlı talep tahminleri için üç farklı model kullanılmıştır:

- Prophet
- LSTM
- XGBoost

Her model farklı avantajlara sahiptir ve farklı veri yapılarıyla en uygun sonucu verecek şekilde tasarlanmıştır.

Neden Kullanıldı

- Facebook tarafından geliştirilen, zaman serisi verilerde trend ve mevsimsellik yakalamada güçlüdür.
- Kampanya etkileri gibi dışsal değişkenleri `add_regressor` ile modele entegre edebilir.

Tahmin (Forecasting) Modelleri: Prophet Modeli

Avantajları

- Model açıklanabilirliği yüksek
- Mevsimsel dalgalanmaları başarılı şekilde yakalar
- Az veriyle de çalışabilir
- Veri miktarı azsa
- Açıklanabilirlik önemliyse
- Trend ve mevsimsellik barizse
- Operasyonel kararlarda şeffaflık gerekiyorsa
- Düşük varyanslı tahminler isteniyorsa

Dezavantajları

- Ani değişimleri (örneğin kampanya kaynaklı) yavaş öğrenir
- Her kombinasyon için ayrı model eğitmek gerekebilir (bu projede tek modelde çözüldü)

Neden Kullanıldı

- Zaman serisi verilerde geçmiş verilerle uzun dönemli bağımlılıkları modelleyebilmesi için tercih edildi.
- *sin/cos* zaman kodlama, kampanya gibi ek girdilerle zenginleştirildi.

Tahmin (Forecasting) Modelleri: LSTM

Avantajları

- Mevsimsel yapı, trend, kampanya gibi faktörleri birlikte öğrenebilir
- Farklı varyantları tek modelde işleyebilir
- Zengin zaman serisi varsa (örneğin son 3–5 yılın verisi)
- Karmaşık desenler ve bağımlılıklar varsa
- Gecikmeli/bağımlı etkiler önemliyse
- Öngörülen değişkenin geçmişe sıkı bağlı olduğu durumlar

Dezavantajları

- Daha uzun eğitim süresi
- Hiperparametre ayarlamaları karmaşık
- Yorumlanabilirliği düşüktür

Neden Kullanıldı

- Zaman serisi veri ile birlikte varyant, kanal, kampanya gibi çok sayıda özelliği işleyebildiği için tercih edildi.
- Diğer modellere kıyasla hızlı ve etkili tahmin gücü sundu.

Tahmin (Forecasting) Modelleri: XGBoost

Avantajları

- Yüksek doğruluk
- Hızlı eğitim ve tahmin
- Öznitelik mühendisliğiyle esnek yapı
- Özellik mühendisliği yapılmışsa (kanal, kampanya, tarih gibi)
- Tahmin doğruluğu ön plandaysa
- Daha hızlı ve agresif tahmin isteniyorsa
- Heterojen veri (çok değişkenli) varsa

Dezavantajları

- Zaman bileşenleri doğrudan öğrenilmez, \sin/\cos dönüşüm gerekebilir
- Doğrusal olmayan yapıdan dolayı yorumlaması zordur

Tahmin (Forecasting) Modelleri: Model Özelliklerinin Karşılaştırması

Özellik	Prophet	XGBoost	LSTM
Zaman Serisi Yapısı	Trend + mevsimsellik modeller	Zaman bağımlılığı zayıf	Güçlü zaman bağımlılığı modeli
Açıklanabilirlik	Çok yüksek	Orta	Düşük
Veri Miktarı İhtiyacı	Az	Orta	Yüksek
Kampanya / dışsal etkiler	add_regressor ile desteklenir	Özellik olarak eklenir	Doğrudan öğrenebilir
Eğitim Süresi	Çok kısa	Kısa	Uzun
Genel Güvenilirlik	Yüksek (düşük varyans)	Yüksek doğruluk	Karmaşık ama güçlü
Uç Değerlere Tepki	Yavaş	Agresif	Veri miktarına bağlı

Tablo: Zaman serisi modelleme yaklaşımlarının temel özelliklere göre karşılaştırılması

Train / Test Veri Seti Hazırlanması

Tarih	Mağaza	Ürün	Renk	Beden	Kanal	Satış	Kategori	Alt Kategori	Key	İndirim	Tip	Kampanya
2022-01-01	38	1	Kırmızı	M	Online	11	Çocuk Giyim	Body	1	0.0		0
2022-01-02	2	1	Kırmızı	M	Online	12	Çocuk Giyim	Body	1	0.0		0
2022-01-03	43	1	Kırmızı	M	Online	4	Çocuk Giyim	Body	1	0.0		0
2022-01-04	21	1	Kırmızı	M	Fiziksel	6	Çocuk Giyim	Body	1	0.0		0
2022-01-05	41	1	Kırmızı	M	Online	3	Çocuk Giyim	Body	1	30.0	Etiket Üzerinden %	1
2022-01-06	43	1	Kırmızı	M	Fiziksel	0	Çocuk Giyim	Body	1	30.0	Etiket Üzerinden %	1
2022-01-07	38	1	Kırmızı	M	Online	8	Çocuk Giyim	Body	1	30.0	Etiket Üzerinden %	1
2022-01-08	6	1	Kırmızı	M	Online	4	Çocuk Giyim	Body	1	30.0	Etiket Üzerinden %	1
2022-01-09	16	1	Kırmızı	M	Online	4	Çocuk Giyim	Body	1	30.0	Etiket Üzerinden %	1
2022-01-10	41	1	Kırmızı	M	Online	10	Çocuk Giyim	Body	1	30.0	Etiket Üzerinden %	1
2022-01-11	17	1	Kırmızı	M	Online	6	Çocuk Giyim	Body	1	30.0	Etiket Üzerinden %	1
2022-01-12	7	1	Kırmızı	M	Online	5	Çocuk Giyim	Body	1	0.0		0

Tablo: 2022 Ocak ayı satış verileri (ürün: 1, renk: Kırmızı, beden: M)

Train / Test Veri Seti Hazırlanması

Veri Yükleme ve Zaman Öznitelikleri

Satış tahminine yönelik bu çalışmada, ilk olarak kampanya bilgilerini de içeren zaman serisi tabanlı veri seti CSV formatında yüklenmiş ve tarih sütunu datetime biçiminde yorumlanmıştır. Zaman bileşenleri olarak haftanın günü (dayofweek), ay (month) ve yıl içi hafta numarası (week) bilgileri çıkarılmış, bu öznitelikler sinüs ve kosinüs dönüşümleriyle döngüsel yapılara dönüştürülerek mevsimsellik etkileri modele entegre edilebilir hâle getirilmiştir.

Kategorik Değişkenlerin Dönüşümü

Kategorik değişkenler (örneğin kategori, alt kategori, renk, beden, kanal, kampanya tipi) LabelEncoder yöntemi ile sayısal forma dönüştürülmüş, bu işlemde her sütun için özel encoder nesnesi saklanarak yeniden kullanılabilirlik sağlanmıştır.

Train / Test Veri Seti Hazırlanması

Öznitelik Seçimi ve Veri Ayrımı

Öznitelik seti, ürün ve mağaza kimlikleri, kategorik değişkenler, kampanya durumu ve oranı, zaman bileşenleri gibi toplam 16 girdi değişkeni ile oluşturulmuştur. Hedef değişken olarak satış miktarı (`sales`) seçilmiştir. Modelin geçmiş verilerle eğitilip gelecek döneme yönelik tahmin yapabilmesi amacıyla, veri seti kronolojik sıraya göre 01.01.2022 - 31.12.2023 tarihini referans eğitim, ve 01.01.2024 - 31.12.2024 test seti olmak üzere ayrıştırılmıştır.

Verilerin Dışa Aktarılması

Son olarak, eğitim ve test veri setlerine ait girdi (`X_train`, `X_test`) ve hedef (`y_train`, `y_test`) dosyaları `.csv` formatında dışa aktarılmış ve modelleme sürecine hazır hâle getirilmiştir.

Model Eğitim ve Test Sonuçları: LSTM ile Talep Tahmini

Veri Yükleme

`product_id = 7` olan ürüne ait geçmiş 7 günlük pencere verileri kullanılarak eğitim (`X_train`, `y_train`) ve test (`X_test`, `y_test`) veri setleri `.npy` formatında yüklenmiştir. Test kümesine karşılık gelen tarihsel bilgiler ayrıca `test_info.csv` dosyasından alınmıştır.

Model Eğitim ve Test Sonuçları: LSTM ile Talep Tahmini

Model Mimarisi

Model, sırasıyla şu katmanlardan oluşmaktadır:

- 64 nöronlu tek katmanlı LSTM bloğu (`return_sequences=False`),
- %20 oranında Dropout katmanı,
- 32 nöronlu ReLU aktivasyonlu yoğun (`dense`) katman,
- 1 nöronlu çıkış katmanı (regresyon için).

Model Adam optimizasyon algoritması ve MeanSquaredError kayıp fonksiyonu ile derlenmiştir.

Model Eğitim ve Test Sonuçları: LSTM ile Talep Tahmini

Model Eğitimi ve Doğrulama

Eğitim sürecinde doğrulama verisinin %10'u ayrılmış ve erken durdurma (EarlyStopping) tekniği uygulanmıştır. `val_loss` değerinde 5 epoch boyunca iyileşme olmaması durumunda eğitim sonlandırılmış ve en iyi model ağırlıkları geri yüklenmiştir.

Sonuçların Kaydedilmesi

Tahmin sonuçları, tarih ve varyant bilgileriyle birleştirilerek `forecast_results.csv` dosyasına kaydedilmiştir. Eğitilen model `.h5` formatında saklanarak ileriye dönük yeniden kullanılabilir hâle getirilmiştir.

Model Eğitim ve Test Sonuçları: Prophet ile Talep Tahmini

Modelleme Yaklaşımı

Prophet modeli, belirli bir ürünün tüm varyantları (renk + beden) için ayrı ayrı eğitilmiştir. Model girdi veri seti Prophet formatına uygun olarak x s (tarih) ve y (satış) sütunlarıyla hazırlanmıştır.

Dışsal Değişkenler

Kampanya durumu (`is_campaign`) ve indirim oranı (`discount`) değişkenleri Prophet modeline dışsal regressor olarak dahil edilmiştir. Bu sayede model sadece mevsimsellik ve trend etkilerini değil, kampanyaların etkisini de tahmin sürecine katabilmiştir.

Model Eğitim ve Test Sonuçları: Prophet ile Talep Tahmini

Eğitim ve Tahmin Süreci

Her varyant için yeterli veri bulunan durumlarda Prophet modeli eğitilmiş, belirlenen test tarih aralığında tahmin yapılmıştır. Gerçek ve tahmin edilen satışlar birleştirilerek her varyant için günlük bazda y_{true} ve y_{pred} karşılaştırması yapılmıştır.

Model Performansı ve Kayıt

Model başarıımı RMSE ve MAE metrikleriyle değerlendirilmiş ve elde edilen sonuçlar çıktı olarak raporlanmıştır. Tahmin sonuçları .csv formatında saklanmış; Prophet model nesnesi ise yeniden kullanım için .pkl uzantısıyla serileştirilmiştir.

Model Eğitim ve Test Sonuçları: XGBoost ile Talep Tahmini

Veri Hazırlık Süreci

Belirli bir ürün (`product_id = 7`) için geçmiş satış verileri filtrelenmiş ve tarih bilgilerinden haftanın günü, ay ve ISO hafta numarası elde edilmiştir. Bu öznitelikler sinüs/kosinüs dönüşümüyle döngüsel forma getirilerek modele mevsimsellik kazandırılmıştır.

Kategorik Değişkenlerin Dönüştürülmesi

`color`, `size`, `channel`, `category`, `subcategory` ve `type` sütunları `LabelEncoder` ile sayısallaştırılmış; `color` ve `size` için oluşturulan etiketleyiciler ileri kullanım amacıyla `.pkl` olarak kaydedilmiştir.

Model Eğitim ve Test Sonuçları: XGBoost ile Talep Tahmini

Model Eğitimi ve Tahmin

Veri seti 1 Ocak 2024 tarihine göre eğitim ve test verisi olarak ayrılmıştır. XGBRegressor, 100 ağaç, 0.1 öğrenme oranı ve maksimum 6 derinlik ile eğitilmiştir. Model, test seti üzerinden tahmin yaparak sonuçları gerçek değerlerle karşılaştırmıştır.

Performans Değerlendirmesi

Modelin başarımı şu metriklerle değerlendirilmiştir:

- **RMSE (Root Mean Squared Error):** XX.XX
- **MAE (Mean Absolute Error):** XX.XX

Tahmin sonuçları .csv formatında dışa aktarılmış, model ise .pkl uzantısı ile kaydedilmiştir.

Model Eğitim ve Test Sonuçları: MAE – Mean Absolute Error

MAE - (Ortalama Mutlak Hata)

- MAE, tahmin edilen değerler ile gerçek değerler arasındaki farkların mutlak değerlerinin ortalamasıdır.
- Hataların büyüklüğünü dorudan ölçer.

Formül:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Not: Aykırı değerlere karşı daha az hassastır.

Model Eğitim ve Test Sonuçları: RMSE – Root Mean Squared Error

RMSE - (Karekök Ortalama Kare Hata)

- RMSE, tahmin hatalarının karelerinin ortalamasının kareköküdür.
- Büyük hatalar daha fazla cezalandır.

Formül:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Not: Aykırı değerlere karşı daha duyarlıdır.

Model Eğitim ve Test Sonuçları: MAE ve RMSE Karşılaştırması

Özellik	MAE	RMSE
Hata Türü	Mutlak Hata	Kare Hata
Aykırı Değerlere Duyarlılık	Az	Yüksek
Yorumu	Daha sezgisel	Daha teknik
Birim	Orijinal birim	Orijinal birim


Tablo: MAE ve RMSE metriklerinin temel farklarının karşılaştırılması

Model Eğitim ve Test Sonuçları: Test Sonuçları

Model	MAE	RMSE
Prophet	19.20	24.60
XGBoost	15.80	20.50
LSTM	17.30	22.10

Tablo: Test Veri Setine ait başarımların sonuçları.

Model Eğtim ve Test Sonuçları: Model Tahmini Karşılaştırması



Şekil: Test Veri Setine Ait Tahmin Sonucu

İşletme Parametreleri Kullanılarak Yapılan Hesaplamalar: Ekonomik Sipariş Miktarı (EOQ)

$$EOQ = \sqrt{\frac{2DS}{H}} \quad (1)$$

- D : Yıllık talep miktarı (adet)
- S : Sipariş başına sabit maliyet
- H : Birim başına yıllık stok tutma maliyeti

EOQ, toplam sipariş ve stok tutma maliyetlerini minimize edecek optimal sipariş miktarını belirler.

Stok yönetimde maliyet etkinliğini artırır; aşırı veya yetersiz sipariş kaynaklı kayıpların önüne geçilmesini sağlar.

İşletme Parametreleri Kullanılarak Yapılan Hesaplamalar: Yeniden Sipariş Noktası (ROP)

$$ROP = d \cdot L + SS \quad (2)$$

- d : Ortalama günlük talep
- L : Tedarik süresi (gün)
- SS : Güvenlik stoğu

ROP, stok seviyesinin bu değere ulaşması durumunda yeni sipariş verilmesi gerektiğini gösterir.

Tedarik süresi boyunca stok tükenmesini önleyerek süreçlerin kesintisiz devam etmesini sağlar.

İşletme Parametreleri Kullanılarak Yapılan Hesaplamalar: Güvenlik Stoğu (Safety Stock)

$$SS = Z \cdot \sigma_L \quad (3)$$

- Z : Servis seviyesi katsayısı (örneğin %95 için $Z \approx 1.65$)
- σ_L : Tedarik süresindeki talep sapmasının standart sapması

Güvenlik stoğu, talepteki belirsizlikler veya tedarik gecikmeleri karşısında oluşabilecek stok yetersizliğine karşı ek stok miktarıdır.

Müşteri hizmet seviyesini artırır, stok outs (stok tükenmesi) riskini azaltır ve operasyonel sürekliliği destekler.

İşletme Parametreleri Kullanılarak Yapılan Hesaplamalar: Toplam Maliyet Bileşenleri

$$\begin{aligned}\text{Toplam Maliyet} &= \text{Sipariş Maliyeti} \\ &+ \text{Stok Tutma Maliyeti} \\ &+ \text{Eksik Maliyet}\end{aligned}\quad (4)$$

Toplam maliyet, stok yönetiminde dikkate alınan üç temel kalemten oluşur. Her bir bileşen farklı operasyonel riski temsil eder.

İşletme Parametreleri Kullanılarak Yapılan Hesaplamalar: Model Bazlı Maliyet Hesaplama Formülleri

$$\text{Sipariş Maliyeti} = \frac{D}{EOQ} \cdot S \quad (5)$$

$$\text{Stok Tutma Maliyeti} = \frac{EOQ}{2} \cdot H \quad (6)$$

$$\text{Eksik Maliyet} = \frac{D}{EOQ} \cdot (ROP - EOQ) \cdot C \quad (7)$$

Eksik maliyet, talep karşılanamadığında oluşan fırsat maliyetini temsil eder. C : birim başına eksiklik maliyetidir.

Prompt Parametreleri

- product_id: 7
- mevcut_stok: 22
- teslim_suresi: 7
- siparis_maliyeti: 50
- stok_tutma_maliyeti: 5
- servis_seviyesi: 0.95
- stockout_cost: 20
- start_date: 2025-05-01
- end_date: 2025-05-07

Tahmin ve Optimizasyon: Prompt

Ürün ID: {parameters["product_id"]}

Tahmin edilen tarih aralığı: {parameters["start_date"]} - {parameters["end_date"]}

İşletme Parametreleri:

- Mevcut stok: {parameters["mevcut_stok"]}
- Teslim süresi: {parameters["teslim_suresi"]} gün
- Servis seviyesi: %{parameters["servis_seviyesi"] * 100}
- Sipariş maliyeti: {parameters["siparis_maliyeti"]} TL
- Stok tutma maliyeti: {parameters["stok_tutma_maliyeti"]} TL
- Stoksuz kalma maliyeti (stockout cost): {parameters["stockout_cost"]} TL

Prophet modeli çıktısı:

Model Tahminleri: {df_prophet_forecast_dict}

Stok Hesaplamaları: {stock_calculation_prophet}

Varyant Risk Skorları: {variant_risk_prophet_df.to_dict(orient='records')}

Toplam Maliyet Analizi: {costs_prophet}

XGBoost modeli çıktısı:

Model Tahminleri: {df_xgboost_forecast_dict}

Stok Hesaplamaları: {stock_calculation_xgboost}

Varyant Risk Skorları: {variant_risk_xgb_df.to_dict(orient='records')}

Toplam Maliyet Analizi: {costs_xgboost}

Tahmin ve Optimizasyon: Prompt

Lütfen aşağıdaki konuları analiz et:

1. Prophet ve XGBoost modellerinin genel tahmin ortalaması ve varyansı nedir? Hangi model daha istikrarlı ve güvenilir?
2. Her modelin EOQ, ROP ve SS değerlerini karşılaştır. Hangisi daha uygun sipariş stratejisi sunuyor?
3. Toplam maliyet analizine göre hangi model işletmeye daha az maliyet çıkarıyor? (Stok tutma, sipariş ve stoksuz kalma maliyetleri dahil)
4. Varyant bazlı risk skorlarını incele. Yüksek riskli varyantlar hangileri ve nasıl önceliklendirilmelidir?
5. Sipariş önerisi:
 - Toplam kaç adet sipariş verilmelidir?
 - Hangi varyantlara öncelik verilmeli? (Risk skorlarına göre grupla)
6. Tüm analizleri göz önünde bulundurarak nihai model seçimini yap.
7. Kararını açık ve gerekçeli şekilde sun:
 - Servis seviyesi, stok-out riski, maliyetler, varyant dengesi ve operasyonel uygulanabilirlik açısından değerlendir.
 - Nihai sipariş miktarını belirt ve işletmeye önerini ilet.

Tahmin ve Optimizasyon: Model Bazlı Tahmin Sonuçları

Model	Ortalama Tahmin	Varyans
Prophet	9.59	1.56
XGBoost	11.65	2.63

Tablo: Prophet ve XGBoost modellerinin 7 günlük tahmin ortalaması ve varyans değerleri

Agent Analizleri: EOQ / ROP / SS Karşılaştırması

Model	EOQ	ROP	SS
Prophet	380.75	73.90	6.78
XGBoost	419.76	93.01	11.44

Tablo: EOQ, ROP ve SS değerlerinin Prophet ve XGBoost modellerine göre karşılaştırılması

Agent Analizleri: Sipariş Stratejisi Analizi

- XGBoost modeli daha yüksek EOQ, ROP ve SS değerlerine sahiptir.
- Bu, XGBoost'un daha büyük sipariş miktarları ve daha yüksek güvenlik stokları önerdiği anlamına gelir.
- Ancak, bu durum daha fazla maliyet anlamına gelebilir.
- Prophet modeli daha düşük değerler sunarak daha az riskli bir sipariş stratejisi sunmaktadır.

Agent Analizleri: Toplam Maliyet Karşılaştırması

Model	Toplam Maliyet (TL)
Prophet	2 039.87
XGBoost	2 519.71

Tablo: Prophet ve XGBoost modellerine göre toplam stok maliyeti değerleri

Analiz: Prophet modeli, toplam maliyet açısından daha avantajlıdır. Daha düşük maliyetler, işletmenin karlılığını artırır.

Yüksek Riskli Varyantlar:

Tüm varyantlar (Kırmızı, Mavi, Siyah) için risk skorları 0.855 ile 0.884 arasında değişmektedir. Bu, tüm varyantların yüksek risk taşıdığını göstermektedir.

Önceliklendirme: Tüm varyantlar yüksek risk taşıdığı için, sipariş önceliği verilmesi gereken varyantlar arasında ayırım yapmak zordur. Ancak, XGBoost modelinin tahminleri daha yüksek olduğu için, bu modelin tahminlerine göre sipariş verilmesi önerilebilir.

Agent Analizleri: Toplam Sipariş Miktarı ve Varyant Dağılımı

- **Toplam Sipariş Miktarı:**

- Prophet: 51.90 adet
- XGBoost: 71.01 adet

- **Varyantlara Öncelik:**

- Tüm varyantlar yüksek risk taşımaktadır.
- Sipariş miktarları eşit dağıtılabilir.
- XGBoost modelinin öngördüğü talep artışı dikkate alınarak, varyant başına sipariş miktarı artırılabilir.

Seçilen Model: Prophet

Prophet modeli aşağıdaki nedenlerle tercih edilmiştir:

- Daha düşük toplam maliyetler sunar.
- Tahmin varyansı daha düşüktür (daha istikrarlı).
- Daha düşük EOQ ve ROP değerleriyle **daha az sermaye bağlar.**
- Risk yönetimi açısından daha temkinli ve kontrollüdür.

Agent Analizleri: Nihai Karar ve İşletmeye Öneri

Servis Seviyesi: %95 – yüksek müşteri memnuniyeti sağlar.

Stok-out Riski: Prophet modeli ile minimize edilmiştir.

Toplam Maliyet: Prophet modelinde daha düşüktür.

Varyant Dengesi: Hepsi yüksek riskli, eşit dağıtım mantıklıdır.

Operasyonel Uygulanabilirlik: Prophet daha basit ve uygulanabilir bir çözüm sunmaktadır.

Nihai Sipariş Miktarı: **51 adet** (Her varyanta eşit dağıtım önerilir.)

Prophet modeline dayanarak, toplam 51 adet sipariş verilmesi ve bu miktarın tüm varyantlar arasında eşit şekilde dağıtılması önerilmektedir. Bu yaklaşım, maliyetleri minimize ederken müşteri memnuniyetini de artıracaktır.

Agent Analizleri: Nihai Karar ve İşletmeye Öneri

Nihai Sipariş Miktarı: 51 adet (Her varyanta eşit dağıtım önerilir.)

Prophet modeline dayanarak, toplam 51 adet sipariş verilmesi ve bu miktarın tüm varyantlar arasında eşit şekilde dağıtılması önerilmektedir.

Bu yaklaşım, maliyetleri minimize ederken müşteri memnuniyetini de artıracaktır.

İşletme açısından daha karlı ve risksiz görünmektedir.

Teşekkürler!